

DOI: 10.19812/j.cnki.jfsq11-5956/ts.20240828001

基于贝叶斯优化轻量级梯度提升机模型预测 淡水鱼中恩诺沙星抽检结果

宇盛好¹, 周子文¹, 姚 烨^{2*}, 彭少杰^{1*}

(1. 上海市市场监督管理局信息应用研究中心, 上海 200030; 2. 复旦大学公共卫生学院, 上海 200032)

摘 要: **目的** 建立基于贝叶斯优化轻量级梯度提升机(Bayesian optimization light gradient boosting machine, BO-LGBM)的预测模型, 对上海市市售淡水鱼中恩诺沙星的抽检结果进行预测。**方法** 基于 2020—2023 年上海市市售淡水鱼中恩诺沙星的抽检数据, 以抽样地区、抽样月份、抽样环节、抽样场所、检测机构、淡水鱼品种 6 个特征为输入变量, 以淡水鱼中恩诺沙星的抽检结果是否合格为输出变量, 采用十折交叉验证法从 7 种机器学习算法中筛选出的最佳模型作为初始模型, 逐步构建 BO-LGBM 模型及其与 5 种数据重采样方法结合的预测模型。**结果** 上海市市售 11114 件淡水鱼中恩诺沙星的不合格率为 4.7%。其中, 泥鳅中恩诺沙星的不合格率最高(27.1%), 其次为鳊鱼(24.6%)和鳙鱼(18.8%)。相比较其他模型, 采用自适应合成抽样(adaptive synthetic sampling, ADASYN)与 BO-LGBM 结合模型对测试集样品抽检结果预测的准确率(0.83)、召回率(0.86)、F1 值(0.82)和 AUC 值(0.84)均为最高。**结论** ADASYN-BO-LGBM 模型的预测性能好, 能够较为准确地预测淡水鱼中恩诺沙星抽检结果, 为基于问题导向的淡水鱼监督抽检方案制定及风险预警提供技术支撑。**关键词:** 淡水鱼; 恩诺沙星; 贝叶斯优化; 轻量级梯度提升机; 重采样; 预测模型

Prediction of enrofloxacin sampling inspection results in freshwater fish based on Bayesian optimization light gradient boosting machine model

YU Sheng-Hao¹, ZHOU Zi-Wen¹, YAO Ye^{2*}, PENG Shao-Jie^{1*}

(1. Information Application Research Center of Shanghai Municipal Administration for Market Regulation, Shanghai 200030, China; 2. School of Public Health, Fudan University, Shanghai 200032, China)

ABSTRACT: Objective To establish a prediction model based on Bayesian optimization light gradient boosting machine (BO-LGBM) for predicting the sampling inspection results of enrofloxacin in freshwater fish sold in Shanghai. **Methods** Based on the sampling inspection data of enrofloxacin in freshwater fish sold in Shanghai from 2020 to 2023, the 6 kinds of characteristics included sampling area, sampling month, sampling process, sampling site, testing institution, and freshwater fish species were taken as input variables, and whether the sampling inspection results of enrofloxacin in freshwater fish were qualified as the output variables. The best model selected from 7 kinds of machine learning algorithms used ten fold cross validation was used as the initial model, and the

基金项目: 国家市场监督管理总局科技计划项目(2022MK034)

Fund: Supported by the Science and Technology Plan Project of State Administration for Market Regulation (2022MK034)

***通信作者:** 姚 烨, 博士, 副教授, 主要研究方向为医学大数据分析。E-mail: yyao@fudan.edu.cn

彭少杰, 硕士, 主任医师, 主要研究方向为食品安全风险监测与评估。E-mail: pengshaojie2008@qq.com

***Corresponding author:** YAO Ye, Ph.D, Associate Professor, School of Public Health, Fudan University, No.131, Dongan Road, Xuhui District, Shanghai 200032, China. E-mail: yyao@fudan.edu.cn

PENG Shao-Jie, Master, Chief Physician, Information Application Research Center of Shanghai Municipal Administration for Market Regulation, No.2598, Xietu Road, Xuhui District, Shanghai 200030, China. E-mail: pengshaojie2008@qq.com

BO-LGBM model and the prediction model combined with 5 kinds of data resampling methods were gradually constructed. **Results** The unqualified rate of enrofloxacin in 11114 pieces of freshwater fish sold in Shanghai was 4.7%. Among them, the unqualified rate of enrofloxacin in *Misgurnus anguillicaudatus* was the highest (27.1%), followed by *Monopterus albus* (24.6%) and *Parabramis pekinensis* (18.8%). Compared with other models, the adaptive synthetic sampling (ADASYN) combined with BO-LGBM model had the highest accuracy (0.83), recall (0.86), F1 value (0.82), and AUC value (0.84) in predicting the sampling inspection results of the test set samples. **Conclusion** The ADASYN-BO-LGBM model has the better predictive performance and can accurately predict the sampling results of enrofloxacin in freshwater fish, which can provide technical support for problem-oriented freshwater fish supervision sampling plan formulation and risk warning.

KEY WORDS: freshwater fish; enrofloxacin; Bayesian optimization; light gradient boosting machine; resampling; predictive model

0 引言

随着我国居民消费水平的不断提高和食品安全意识的增强,淡水鱼因较高的蛋白质含量以及较低的脂肪比例等特点,而深受消费者的喜爱。目前,由于防控细菌性疾病等需要,养殖环节喹诺酮类兽药使用十分普遍,由此造成的淡水鱼质量安全风险问题日益突出,淡水鱼的质量安全备受广大消费者的关注。恩诺沙星属于氟喹诺酮类药物,具有抗菌谱广、抗菌能力强的特点,在动物体内的代谢物为环丙沙星,广泛用于水产养殖业^[1-2]。近年来,我国市场监管部门在开展食品安全监督抽检工作中,发现淡水鱼中恩诺沙星残留超标问题时有发生。长期食用恩诺沙星残留超标的食品,可引起轻度胃肠道刺激或不适,会导致人体产生耐药性,甚至引起肝脏、肾脏的损害以及生殖毒性等^[3-4]。

食品安全监督抽检有助于及时发现食品风险隐患,保障食品安全。机器学习具备对大数据的强大分析能力,能够准确识别食品安全风险发生的多维度关联特征并预测风险,进而为食品安全监管提供可靠的依据^[5]。目前预测食品安全风险所使用的机器学习方法主要包括贝叶斯网络(Bayesian network, BN)^[6-7]、最邻近分类算法(k-nearest neighbor, KNN)^[8]、反向传播(back propagation, BP)神经网络^[9-10]、径向基函数(radial basis function, RBF)神经网络^[11]、长短期记忆神经网络(long short-term memory, LSTM)^[12-13]、支持向量机(support vector machine, SVM)^[14]、决策树(decision tree, DT)^[15-16]、随机森林(random forest, RF)^[16-17]、极端梯度提升树算法(extreme gradient boosting, XGBoost)^[18-19]、轻量级梯度提升机(light gradient boosting machine, LGBM)^[20-23]等。

食品安全抽检结果一般不平衡,合格样品数量远多于不合格样品,少数不合格样品被错误分类的成本远高于多数合格样品被错误分类的代价^[24]。因此,对不平衡数据集采用重采样方法进行预测模型构建非常重要。重采样方法包括过采样、欠采样以及混合采样方法。其中,过采样方法主要包括合成少数类过采样技术(synthetic minority

oversampling technique, SMOTE)、Borderline-SMOTE、自适应合成抽样(adaptive synthetic sampling, ADASYN)以及随机过采样等^[25-26];欠采样方法包括 Tomek Link、ClusterCentroids、随机欠采样等^[27];混合采样方法包括 SMOTEENN、SMOTETomek 等^[27]。杨鸿雁等^[24]采用 2015—2017 年新疆食品监督抽检数据,构建了多种采样方法(包括随机采样、过采样、欠采样)、代价敏感方法分别与 SVM、RF 的组合模型,发现代价敏感方法-SVM 组合模型的预测性能最好。穆书敏等^[18]利用 2013—2017 年肉制品抽检数据构造了 5 个安全风险等级,通过构建 XGBoost 模型研究食品生产过程各类因素对于食品安全风险等级的影响程度,结果表明 XGBoost 经过贝叶斯优化(bayesian optimization, BO)参数调节后预测性能得到有效地提升,并且不同采样下 XGBoost 的平均准确率、平均 F1 值分别为 89.14%和 88.59%。

本研究利用 2020—2023 年上海市市售淡水鱼中恩诺沙星(以恩诺沙星和环丙沙星之和计,简称恩诺沙星)的抽检数据,以抽样地区、抽样月份、抽样环节、抽样场所、检测机构、淡水鱼品种 6 个属性指标为输入变量,以淡水鱼中恩诺沙星的抽检结果是否合格为输出变量,采用多种重采样方法和贝叶斯优化 BO-LGBM 模型进行组合,选择预测性能最佳模型来预测淡水鱼中恩诺沙星的抽检结果,为监管部门进一步做好淡水鱼的靶向监督抽检和科学监管提供技术参考。

1 材料与方法

1.1 样品来源

2020—2023 年上海市市售淡水鱼样品来源于上海市市场监管部门组织开展的食品安全抽检数据,共抽检 11114 件样品。按照淡水鱼的品种分,包括鲫鱼、乌鳢、鳊鱼、鲈鱼、鳙鱼、鳊鱼等 27 种。样品随机采集于上海市的流通环节(包括超市、网店、农贸市场、批发市场、食品店等)和餐饮环节(包括特大型餐馆、大型餐馆、中型餐馆、小型餐馆、单位食堂等)。抽样地区覆盖了上海市的 16 个区。

1.2 检测方法

淡水鱼中恩诺沙星(以恩诺沙星和环丙沙星之和计)的检验方法为农业部 1077 号公告-1-2008《水产品中 17 种磺胺类及 15 种喹诺酮类药物残留量的测定 液相色谱-串联质谱法》(恩诺沙星和环丙沙星的检出限均为 1.0 $\mu\text{g/kg}$)和 GB/T 20366—2006《动物源产品中喹诺酮类残留量的测定 液相色谱-串联质谱法》(恩诺沙星、环丙沙星的检出限分别为 0.5 $\mu\text{g/kg}$ 和 0.1 $\mu\text{g/kg}$)。本研究按照 GB 31650—2019《食品安全国家标准 食品中兽药最大残留限量》中淡水鱼的恩诺沙星(以恩诺沙星和环丙沙星之和计)最大残留限量(100 $\mu\text{g/kg}$)对样品的检测结果进行评价。

1.3 预测模型构建方法

1.3.1 机器学习模型筛选

用于分类的机器学习模型通过预测一组离散值中的标签来实现预测。当应用于分布不均衡的数据集时,传统的机器学习模型主要认为两个类别的准确性同样重要,其性能会大幅下降^[28]。为了解决这个问题,研究者从数据预处理和算法层面两个维度改进相关算法模型^[25],以便能够更好的处理不平衡数据。对于样本分布不均衡的数据而言,模型的准确度并不能作为唯一评判标准。因此,本研究选择了 7 种机器学习模型(Logistic 回归、SVM、KNN、BP 神经网络、RF、XGBoost、LGBM),将淡水鱼样本(11114 件)全部作为数据集输入 7 种模型,以 AUC 值为目标值,经过十折交叉验证(k-Fold, k=10)方法筛选表现最佳的模型,作为后续研究的基础模型。

1.3.2 BO-LGBM 预测模型

LGBM 是一种基于梯度提升决策树(gradient boosting

decision trees, GBDT)的机器学习算法。LGBM 模型在训练数据上采用单边梯度采样,并采用互斥特征捆绑法达到特征降维的目的。LGBM 引入直方图算法,在其基础上采用带深度限制的按叶子生长决策树算法,使模型的学习效率提高,并防止过拟合现象,提高了模型的训练速度和泛化能力^[29]。LGBM 模型的核心思想是将连续型特征值离散化后作为索引,以直方图中离散值的累计量为依据迭代寻优,最终得到最佳分割点。叶子生长策略使 LGBM 算法在每次迭代过程中从所有叶子节点中找到分裂增益最佳的叶子结点进而分裂,以达到低误差、高精度结果的目的。同时, LGBM 使用带有深度限制的按叶子生长算法,在保证高效率的同时,可以防止过拟合。

在 LGBM 模型中,不同超参数的组合得到的预测效果不同。为了获得良好的预测效果,需要优化模型的参数,得到最佳参数组合。BO 是优化黑箱问题的经典方法,基于概率模型的全局优化方法,主要包括先验函数和采集函数^[30]。BO 通过构建概率模型来对目标函数进行建模,并在此模型上迭代搜寻最优解^[31-32]。BO 在超参数调优方面具有迭代次数少、速度快的优点,可以确保在指定的参数范围内寻找到模型预测结果精度最高的参数组合。

因此,本研究基于淡水鱼中恩诺沙星抽检数据构建 BO-LGBM 预测模型,算法流程图如图 1 所示。该模型采用 BO 算法,以 AUC 值为目标,通过十折验证法确定 LGBM 模型的最佳参数组合,优化的超参数包括:决策树数量、学习率、每次迭代时用来训练的特征比例、叶节点样本的最少数量、树的最大深度、每次迭代时用来训练的数据比例、叶子的个数、决策树的个数。




图 1 BO-LGBM 模型构建流程图
Fig.1 Flowchart of BO-LGBM model construction

1.3.3 数据预处理

从淡水鱼抽检信息中选择合适的特征作为输入变量。本研究选择抽样地区、抽样月份、抽样环节、抽样场所、检测机构、淡水鱼品种 6 个代表性特征为输入变量,以淡水鱼中恩诺沙星的抽检结果(合格或者不合格)为输出变量。对模型中涉及的分类变量进行赋值,见表 1。

鉴于采用的淡水鱼抽检数据集分布不平衡,本研究采用 5 种数据重采样方法平衡数据集,包括过采样(Borderline-SMOTE、ADASYN)、欠采样(ClusterCentroids)以及混合采样(SMOTETomek、SMOTEENN)方法,如表 2 所示。本研究将 8891 件淡水鱼样本(包括 421 件不合格样本和 8470 件合格样本)输入模型进行重采样和训练模型,然后在剩余的 20%样本中随机抽取 228 件样本(包括 104 件不合格样本和 124 件合格样本)作为测试集来测试模型的预测性能。

1.3.4 模型评价

本研究采用准确率、精准率、召回率、F1 值、AUC 值来综合评价模型的预测性能^[33]。F1 值是对精确率和召回率的加权调和平均数,取值范围为 0~1,数值越大,表明模型预测性能越好。受试者工作特征曲线(receiver operating

characteristic curve, ROC 曲线),是用真阳性率和假阳性率作图得出的曲线。AUC 值为 ROC 曲线下方的面积大小,AUC 值用来评估模型的分类性能,取值范围为 0~1,数值越大,表明模型预测性能越好。准确率、精准率、召回率、F1 值的计算公式见(1)~(4)。

$$\text{准确率}=\frac{TP+TN}{TP+FP+TN+FN} \tag{1}$$

$$\text{精准率}=\frac{TP}{TP+FP} \tag{2}$$

$$\text{召回率}=\frac{TP}{TP+FN} \tag{3}$$

$$F1=2\times\frac{\text{精准率}\times\text{召回率}}{\text{精准率}+\text{召回率}} \tag{4}$$

式中: TP 为实际为不合格,预测也为不合格的样本数; TN 为实际为合格,预测也为合格的样本数; FP 为实际为合格,预测为不合格的样本数; FN 为实际为不合格,预测也为合格的样本数。

1.3.5 SHAP 分析

采用SHAP算法解释BO-LGBM模型在测试集分类过程中的表现,获得每个输入特征对模型预测结果的重要性^[34]。

表 1 模型中涉及的分类变量及其赋值
Table 1 Categorical variables involved in the model and their assignments

变量名称	赋值
淡水鱼品种	鲫鱼=1, 乌鳢=2, 鳊鱼=3, 鲈鱼=4, 鳙鱼=5, 鳊鱼=6, 黄颡鱼=7, 笋壳鱼=8, 鳊鱼=9, 鲢鱼=10, 草鱼=11, 泥鳅=12, 白水鱼=13, 鳊鱼=14, 鲢鱼=15, 鳊鱼=16, 巴沙鱼=17, 鲶鱼=18, 青鱼=19, 淡水石斑鱼=20, 罗非鱼=21, 淡水鳊鱼(短头梭鲃)=22, 鲢鱼=23, 香鱼=24, 鲤鱼=25, 鳊鱼=26, 银鱼=27
抽样月份	1 月—12 月的赋值分别为 1~12
抽样地区	闵行区=1, 宝山区=2, 普陀区=3, 虹口区=4, 浦东新区=5, 嘉定区=6, 松江区=7, 静安区=8, 青浦区=9, 徐汇区=10, 长宁区=11, 崇明区=12, 黄浦区=13, 杨浦区=14, 奉贤区=15, 金山区=16
抽样环节	流通环节=1, 餐饮环节=2
抽样场所	农贸市场(含菜市场)=1, 超市=2, 网购=3, 批发市场=4, 食品店=5, 中型餐馆=6, 大型餐馆=7, 小型餐馆=8, 特大型餐馆和集体用餐配送单位=9, 单位食堂=10
检测机构	16 家检测机构的赋值分别为 1~16
抽检结果	不合格=0, 合格=1

表 2 5 种重采样方法及其原理
Table 2 The 5 kinds of resampling methods and their principles

采样方法类别	采样方法	算法原理
过采样	ADASYN	基于 K-means 的分类器, 在被错误分类的原始样本附近生成新的少数样本
	Borderline-SMOTE	使用边界上的少数类样本来合成新样本
欠采样	ClusterCentroids	使用 K-means 聚类方法来减少多数类样本数量, 并使用 N 个聚类中心的坐标作为新的多数样本集
混合采样	SMOTETomek	先使用 SMOTE 增加少数类样本, 再使用 Tomek Link 识别并移除重叠区域的样本
	SMOTEENN	先使用 SMOTE 增加少数类样本, 再使用 ENN 算法删除多数类样本中与少数类样本距离较近的样本

1.4 数据处理

采用 WPS Office 软件对淡水鱼中恩诺沙星的抽检数据进行整理和统计分析。在 Python 3.11.4 环境下建立基于淡水鱼中恩诺沙星抽检结果的 BO-LGBM 预测模型。

2 结果与分析

2.1 淡水鱼中恩诺沙星的抽检结果

2.1.1 不同品种淡水鱼中恩诺沙星的抽检结果

2020—2023 年共抽检上海市市售淡水鱼样品 11114 件, 有 525 件样品中恩诺沙星的残留量超过限量值(100 μg/kg), 总体不合格率为 4.7% (525/11114)。按照淡水鱼的品种分析, 泥鳅中恩诺沙星的不合格率最高(27.1%), 其次为鳊鱼(24.6%)和鳙鱼(18.8%), 白水鱼、鳊鱼、鲢鱼、巴沙鱼、鲶鱼、淡水石斑鱼等 14 个淡水鱼品种中恩诺沙星均未超标。具体结果见表 3。

表 3 上海市市售淡水鱼中恩诺沙星的抽检结果
Table 3 Sampling inspection results of enrofloxacin in freshwater fish sold in Shanghai

淡水鱼品种	总件数/件	不合格件数/件	不合格率/%
鲫鱼	1911	69	3.6
乌鳢	1638	16	1.0
鳊鱼	1401	263	18.8
鲈鱼	1384	11	0.8
鳙鱼	1173	4	0.3
鳊鱼	773	2	0.3
黄颡鱼	585	7	1.2
笋壳鱼	461	1	0.2
鳊鱼	342	84	24.6
鲢鱼	321	9	2.8
草鱼	278	4	1.4
泥鳅	199	54	27.1
白水鱼	171	0	0.0
鳊鱼	114	0	0.0
鲢鱼	70	0	0.0
鳊鱼	51	0	0.0
巴沙鱼	47	0	0.0
鲶鱼	46	0	0.0
青鱼	44	1	2.3
淡水石斑鱼	30	0	0.0
罗非鱼	25	0	0.0
淡水鳕鱼	11	0	0.0
鲢鱼	10	0	0.0
香鱼	8	0	0.0
鲤鱼	8	0	0.0
鲟鱼	7	0	0.0
银鱼	6	0	0.0
合计	11114	525	4.7

2.1.2 不同抽样月份淡水鱼中恩诺沙星的抽检结果

由表 4 可知, 淡水鱼中恩诺沙星样品的抽样月份覆盖了全年 12 个月。其中, 9 月抽样的淡水鱼中恩诺沙星的不合格率最高(7.8%), 其次为 8 月(6.6%)和 7 月(5.4%), 最低的为 12 月(1.7%)。第 3 季度淡水鱼中恩诺沙星的不合格率偏高, 可能主要与第 3 季度温度偏高, 养殖户为了预防和控制疫病, 违规超量或未遵守休药期使用恩诺沙星兽药有关。

表 4 不同抽样月份淡水鱼中恩诺沙星的抽检结果
Table 4 Sampling inspection results of enrofloxacin in freshwater fish in different sampling months

抽样月份	总件数/件	不合格件数/件	不合格率/%
1	266	9	3.4
2	507	14	2.8
3	807	24	3.0
4	904	35	3.9
5	797	32	4.0
6	750	28	3.7
7	1335	72	5.4
8	1358	90	6.6
9	1445	113	7.8
10	1835	65	3.5
11	992	41	4.1
12	118	2	1.7

2.1.3 不同抽样场所淡水鱼中恩诺沙星的抽检结果

由表 5 可知, 流通环节淡水鱼中恩诺沙星的不合格率为 6.3% (474/7515), 其高于餐饮环节(1.4%)。抽样场所为网购的淡水鱼中恩诺沙星的不合格率最高(9.3%), 其次为食品店(7.8%)和农贸市场(含菜市场)(6.6%), 最低的为特大型餐馆和集体用餐配送单位(0.0%)。

2.2 构建淡水鱼中恩诺沙星的抽检结果预测模型

2.2.1 确定最佳模型

将 11114 件淡水鱼样本全部作为数据集输入 7 种模型, 以 AUC 值为目标, 通过十折验证方法来筛选得到最佳初始模型, 结果如图 2 所示。LGBM 模型的分类性能最佳(AUC 值为 0.871), 因此选择该算法作为后续研究的基础模型。

2.2.2 基于不同重采样方法和 BO-LGBM 组合的预测模型

经 BO 优化后得到 LGBM 模型最佳参数组合为: 决策树数量=403、学习率=0.01、每次迭代时用来训练的特征比例=0.5、叶节点样本的最少数量=20、树的最大深度=9、每次迭代时用来训练的数据比例=0.5、叶子的个数=233、决策树的个数=121。

表 5 不同抽样场所淡水鱼中恩诺沙星的抽检结果
Table 5 Sampling inspection results of enrofloxacin in freshwater fish from different sampling sites

抽样环节	抽样场所	总件数 /件	不合格件数 /件	不合格率 /%
流通环节	农贸市场(含菜市场)	3387	224	6.6
	超市	1461	69	4.7
	网购	1057	98	9.3
	批发市场	843	23	2.7
	食品店	767	60	7.8
	合计	7515	474	6.3
	中型餐馆	1738	27	1.6
餐饮环节	大型餐馆	946	7	0.7
	小型餐馆	798	15	1.9
	特大型餐馆和集体用餐配送单位	64	0	0.0
	单位食堂	53	2	3.8
	合计	3599	51	1.4

由表 6 可知, LGBM 预测模型的准确率、召回率、F1 值和 AUC 值分别为 0.61、0.14、0.25 和 0.57, 而 BO-LGBM 预测模型的准确率、召回率、F1 值、AUC 值分别为 0.67、0.28、0.43 和 0.64, 因此 BO-LGBM 模型比 LGBM 稍好。由于模型中的合格和不合格样本量存在较大不平衡, 而且 BO-LGBM 模型的 F1 值、AUC 值均偏低, 因此需要采用重采样方法对淡水鱼样本数据进行处理, 以进一步提高





图 2 7 种模型的 AUC 值
Fig. 2 AUC values of 7 kinds of models

BO-LGBM 模型预测性能。
本研究根据测试集样品(228 件)绘制了 4 种模型的混淆矩阵(见图 3), 并根据混淆矩阵计算了不同模型的准确率、精确率和召回率和 F1 值(见表 6)。ADASYN-BO-LGBM 预测模型的准确率(0.83)、召回率(0.86)和 F1 值(0.82)均高于其他 4 个重采样方法与 BO-LGBM 的组合模型。本研究还根据测试集样品绘制了 4 种模型 ROC 曲线(见图 4), 从图中可以看出 4 种模型的 AUC 值。通过进一步对比发现, ADASYN-BO-LGBM 模型的 AUC 值(0.84)均高于 ClusterCentroids-BO-LGBM 模型(0.80)、SMOTETomek-BO-LGBM 模型(0.83)和未进行重采样的 BO-LGBM 模型(0.64)。因此本研究选择 ADASYN-BO-LGBM 模型来预测淡水鱼中恩诺沙星的抽检结果。

表 6 基于不同重采样方法和 BO-LGBM 组合建立淡水鱼中恩诺沙星的抽检结果预测模型
Table 6 Prediction models for sampling inspection results of enrofloxacin in freshwater fish based on different resampling methods and BO-LGBM combinations

模型名称	准确率	精确率	召回率	F1 值	AUC 值
LGBM	0.61	1.00	0.14	0.25	0.57
BO-LGBM	0.67	0.97	0.28	0.43	0.64
Borderline-SMOTE-BO-LGBM	0.81	0.78	0.82	0.80	0.81
ADASYN-BO-LGBM	0.83	0.79	0.86	0.82	0.84
ClusterCentroids-BO-LGBM	0.80	0.75	0.83	0.79	0.80
SMOTETomek-BO-LGBM	0.82	0.79	0.84	0.81	0.83
SMOTEENN-BO-LGBM	0.80	0.76	0.81	0.79	0.80



注: A: BO-LGBM; B: ADASYN-BO-LGBM; C: ClusterCentroids-BO-LGBM; D: SMOTETomek-BO-LGBM。

图 3 4 种预测模型的混淆矩阵

Fig.3 Confusion matrix of 4 kinds of prediction models




图 4 4 种预测模型的 ROC 图

Fig.4 ROC diagram of the 4 kinds of prediction models

2.2.3 SHAP 分析

经 SHAP 算法获得每个输入的预测变量对 ADASYN-BO-LGBM 模型预测结果的重要性(见图 5)。在 ADASYN-BO-LGBM 模型中, 淡水鱼品种对预测模型的贡献度最大, 其次为抽样环节和抽样月份, 抽样地区对预测模型的贡献最小。




图5 ADASYN-BO-LGBM模型的SHAP图

Fig.5 SHAP diagram of ADASYN-BO-LGBM

3 结论与讨论

本研究对 2020—2023 年 11114 件上海市市售淡水鱼中恩诺沙星的抽检数据进行统计分析,发现样品中恩诺沙星的不合格率为 4.7%。其中,泥鳅中恩诺沙星的不合格率最高(27.1%),其次为鳊鱼(24.6%)和鳙鱼(18.8%)。按照抽样月份进行分析,发现第 3 季度(7—9 月)淡水鱼中恩诺沙星的不合格率偏高。本研究以抽样地区、抽样月份、抽样环节、抽样场所、检测机构、淡水鱼品种 6 大属性指标为输入变量,以淡水鱼中恩诺沙星的抽检结果是否合格为输出变量,采用十折交叉验证法从 7 种机器学习算法中筛选出的最佳模型作为初始模型,逐步构建 BO-LGBM 模型及其与 5 种数据重采样方法结合的预测模型。本研究结果表明 ADASYN-BO-LGBM 模型的预测准确率、召回率、F1 值、AUC 值总体上均高于其他模型。因此,本研究选择 ADASYN-BO-LGBM 模型作为淡水鱼中恩诺沙星的抽检结果的预测模型。SHAP 分析结果表明,淡水鱼品种对预测模型的贡献度最大。运用该模型,食品监管部门可以通过输入淡水鱼抽检相关的特征信息,预测淡水鱼中恩诺沙星的抽检结果,为淡水鱼监督抽检方案的制定提供参考,提升淡水鱼监督抽检的靶向性和问题食品处置的及时性。

对于不平衡数据,一般需要采用重采样方法对数据进行预处理,然后选择合适的分类模型(如 LGBM)来进行建模预测。LGBM 作为一种高效的集成学习算法,通过多种技术优化提高了训练速度和模型性能,特别适合处理大规模数据,该算法比较适合在食品安全领域进行实际运用。后续研究中,可以通过增加淡水鱼样品抽检样本量、增加更多影响淡水鱼安全的检验项目(如禁限用兽药、重金属项目等)以及输入更多的样品特征(如样品宣称的产地、样品包装等),继续优化 LGBM 等分类模型参数,建立更加科学、准确的淡水鱼安全风险预测模型。

本研究提出以下建议:一是政府部门要加强重点抽样场所(如网购、食品店、农贸市场等)、重点季节(夏季)的典型淡水鱼品种(如泥鳅、鳊鱼和鳙鱼等)的监督抽检和监管,进一步提升食品监督抽检的靶向性和监管效能。二是建立基于淡水鱼抽检数据的风险预测模型和预警系统,准确、快速的预测出淡水鱼中恩诺沙星的超标样品,为淡水鱼安全风险的早期风险预警提供技术支持。

参考文献

- [1] 黄铼玉,方龙香,宋超,等. 抗生素恩诺沙星在渔业中的研究进展[J]. 农学报,2019,9(11): 57-62.
- [2] LIU Y, AI X, SUN R, *et al.* Residue, biotransformation, risk assessment and withdrawal time of enrofloxacin in red swamp crayfish (*Procambarus clarkii*) [J]. Chemosphere, 2022, 307(Pt 1): 135657.
- [3] HOU L, FU Y, ZHAO C, *et al.* Ciprofloxacin and enrofloxacin can cause reproductive toxicity via endocrine signaling pathways [J]. Ecotoxicol Environ Saf, 2022, 244: 114049.
- [4] DAI J, WANG Y, LIN H, *et al.* Residue screening and analysis of enrofloxacin and its metabolites in real aquatic products based on ultrahigh-performance liquid chromatography coupled with high resolution mass spectrometry [J]. Food Chem, 2023, 404(Pt B): 134757.
- [5] 姚仁朋, 孙玉敬, 赵圆, 等. 机器学习在食品工业中的应用[J]. 中国食品学报, 2024, 24(1): 349-363.
- [6] YAO RP, SUN YJ, ZHAO Y, *et al.* The application of machine learning in the food industry [J]. J Chin Inst Food Sci Technol, 2024, 24(1): 349-363.
- [7] YANG YH, WEI LJ, PEI JN. Application of Bayesian modelling to assess food quality & safety status and identify risky food in China market [J]. Food Control, 2019, 100: 111-116.
- [8] LIU N, BOUZEMBRAK Y, BULK LM, *et al.* Automated food safety early warning system in the dairy supply chain using machine learning [J]. Food Control, 2022, 136: 108872.
- [9] 唐昊, 梁江, 吴难, 等. 基于 Smote-KNN 的小麦 8 种真菌毒素共污染特征气候分类模型研究[J]. 中国食品卫生杂志, 2023, 35(6): 807-812.
- [10] TANG H, LIANG J, WU N, *et al.* Climate classification model of co-occurrence characteristics of 8 kinds of mycotoxins in wheat based on Smote-KNN [J]. Chin J Food Hyg, 2023, 35(6): 807-812.
- [11] 李笑曼, 臧明伍, 赵洪静, 等. 基于监督抽检数据的肉类食品安全风险分析及预测[J]. 肉类研究, 2019, 33(1): 42-49.
- [12] LI XM, ZANG MW, ZHAO HJ, *et al.* Analysis and prediction of meat product safety based on supervision and sampling data [J]. Meat Res, 2019, 33(1): 42-49.
- [13] 赵杰斌, 黄穗东, 孙远明, 等. 基于数据挖掘的江门市蔬菜食品安全风险分析与预测[J]. 食品工业科技, 2023, 44(20): 281-288.
- [14] ZHAO JB, HUANG SD, SUN YM, *et al.* Safety risk analysis and prediction of vegetable in Jiangmen City based on data mining [J]. Sci Technol Food Ind, 2023, 44(20): 281-288.
- [15] GENG ZQ, LIU FF, SHANG DR, *et al.* Early warning and control of food safety risk using an improved AHC-RBF neural network integrating AHP-EW [J]. J Food Eng, 2021, 292: 110239.
- [16] GENG ZQ, WANG XT, JIANG YG, *et al.* Novel IAPSO-LSTM neural network for risk analysis and early warning of food safety [J]. Expert Syst Appl, 2023, 230: 120747.
- [17] 陈晨, 尹佳, 董曼, 等. 基于灰色数据预处理的 WD-LSTM 模型对乳制品质量安全风险的预测预警分析[J]. 现代食品科技, 2023, 39(1): 300-310.
- [18] CHEN C, YIN J, DONG M, *et al.* Predictive early warning analysis of dairy product quality and safety risks based on grey data pre-processing using the WD-LSTM model [J]. Mod Food Sci Technol, 2023, 39(1): 300-310.
- [19] 游清顺, 王建新, 张秀宇, 等. 基于支持向量机的食品安全抽检数据分析方法[J]. 软件工程, 2019, 22(2): 29-31.
- [20] YOU QS, WANG JX, ZHANG XY, *et al.* SVM-based analysis on food safety sampling and inspection data [J]. Softw Eng, 2019, 22(2): 29-31.
- [21] 马红迪. 基于决策树和随机森林模型的食品安全风险预警[D]. 大连: 东北财经大学, 2020.
- [22] MA HD. Food safety risk warning based on decision tree and random forest model [D]. Dalian: Dongbei University of Finance and Economics,

- 2020.
- [16] 吴梅凤, 李杨, 李敏敏, 等. 三维荧光光谱法快速检测橄榄油中掺假廉价油[J]. 食品安全质量检测学报, 2024, 15(5): 289–297.
- WU MF, LI Y, LI MM, *et al.* Rapid detection of adulterated cheap oil in olive oil by three-dimensional fluorescence spectrometry [J]. *J Food Saf Qual*, 2024, 15(5): 289–297.
- [17] 周洁红, 魏珂, 金字, 等. 基于机器学习的食品安全风险预测与监管政策启示——以生鲜水产品为例[J]. 农业经济问题, 2024(5): 4–19.
- ZHOU JH, WEI K, JIN Y, *et al.* Food safety risk prediction and regulatory policy implications based on machine learning: Evidence from fresh aquatic products [J]. *J Agri Econ*, 2024(5): 4–19.
- [18] 穆书敏, 陈锂, 尹佳, 等. 基于集成学习优化的肉制品安全风险等级预警分析[J]. 现代食品科技, 2023, 39(8): 273–286.
- MU SM, CHEN L, YIN J, *et al.* Safety risk level early warning of meat products based on optimized ensemble learning [J]. *Mod Food Sci Technol*, 2023, 39(8): 273–286.
- [19] 王小艺, 王姿懿, 赵峙尧, 等. 集成改进 AHP 与 XGBoost 算法的食品安全风险预测模型: 以大米为例[J]. 食品科学技术学报, 2022, 40(1): 150–158.
- WANG XY, WANG ZY, ZHAO ZY, *et al.* A food safety risk forecast model integrated with improved AHP and XGBoost algorithm: A case study of rice [J]. *J Food Sci Technol*, 2022, 40(1): 150–158.
- [20] 高亚男, 王文倩, 王建新. 集成模糊层级划分的 LightGBM 食品安全风险预警模型: 以肉制品为例[J]. 食品科学, 2021, 42(1): 197–207.
- GAO YN, WANG WQ, WANG JX. A food safety risk prewarning model using LightGBM integrated with fuzzy hierarchy partition: A case study for meat products [J]. *Food Sci*, 2021, 42(1): 197–207.
- [21] TACHIE C, TAWIAH NA, ARYEE ANA. Using machine learning models to predict the quality of plant-based foods [J]. *Curr Res Food Sci*, 2023, 7: 100544.
- [22] KANG X, ZHAO Y, YAO L, *et al.* Explainable machine learning for predicting the geographical origin of Chinese Oysters via mineral elements analysis [J]. *Curr Res Food Sci*, 2024, 8: 100738.
- [23] WAN X, ZHANG Y, GAO S, *et al.* Machine learning prediction of exposure to acrylamide based on modelling of association between dietary exposure and internal biomarkers [J]. *Food Chem Toxicol*, 2022, 170: 113498.
- [24] 杨鸿雁, 田英杰. 机器学习在食品安全风险预警及抽检方案制订中的应用研究[J]. 管理评论, 2022, 34(11): 315–323.
- YANG HY, TIAN YJ. Application research of machine learning in food safety risk early warning and sampling inspection program [J]. *Manag Rev*, 2022, 34(11): 315–323.
- [25] 周玉, 孙红玉, 房倩, 等. 不平衡数据集分类方法研究综述[J]. 计算机应用研究, 2022, 39(6): 1615–1621.
- ZHOU Y, SUN HY, FANG Q, *et al.* Review of imbalanced data classification methods [J]. *Appl Res Comput*, 2022, 39(6): 1615–1621.
- [26] ZHU B, JING XN, QIU L, *et al.* An imbalanced data classification method based on hybrid resampling and fine cost sensitive support vector machine [J]. *Comput Mater Con*, 2024, 79(3): 3977–3999.
- [27] 李艳霞, 柴毅, 胡友强, 等. 不平衡数据分类方法综述[J]. 控制与决策, 2019, 34(4): 673–688.
- LI YX, CHAI Y, HU YQ, *et al.* Review of imbalanced data classification methods [J]. *Control Decis*, 2019, 34(4): 673–688.
- [28] WU C, WANG N, WANG Y. Increasing minority recall support vector machine model for imbalanced data classification [J]. *Discrete Dyn Nat Soc*, 2021. DOI:10.1155/2021/6647557
- [29] KE G, MENG Q, FINLEY T, *et al.* Lightgbm: A highly efficient gradient boosting decision tree [EB/OL]. [2017-12-04]. <https://dl.acm.org/doi/10.5555/3294996.3295074> [2024-08-26].
- [30] 宁霄, 贺鑫鑫, 金绍明, 等. 食品快速检测方法的评价及其贝叶斯推断[J]. 食品安全质量检测学报, 2021, 12(3): 1015–1020.
- NING X, HE XX, JIN SM, *et al.* Evaluation of food rapid detection methods and their Bayesian inference [J]. *J Food Saf Qual*, 2021, 12(3): 1015–1020.
- [31] 李亚茹, 张宇来, 王佳晨. 面向超参数估计的贝叶斯优化方法综述[J]. 计算机科学, 2022, 49(S1): 86–92.
- LI YR, ZHANG YL, WANG JC. Survey on Bayesian optimization methods for hyper-parameter tuning [J]. *Comput Sci*, 2022, 49(S1): 86–92.
- [32] JOY TT, RANA S, GUPTA S, *et al.* Fast hyperparameter tuning using Bayesian optimization with directional derivatives [J]. *Knowle-based Syst*, 2020, 205: 106247.
- [33] 孙苏紫. 基于 Smote 与 LightGBM 的食品安全评论文本挖掘分析[D]. 广州: 暨南大学, 2020.
- SUN SZ. Text mining analysis of food safety reviews based on Smote and LightGBM [D]. Guangzhou: Jinan University, 2020.
- [34] JOSEPH A. Shapley regressions: A framework for statistical inference on machine learning models [R]. Bank of England Working Paper, 2019. DOI: 10.2139/ssrn.3351091

(责任编辑: 安香玉 蔡世佳)

作者简介

宇盛好, 硕士, 工程师, 主要研究方向为食品安全风险监测与评估。
E-mail: 850368049@qq.com

姚 烨, 博士, 副教授, 主要研究方向为医学大数据统计分析。
E-mail: yyao@fudan.edu.cn

彭少杰, 硕士, 主任医师, 主要研究方向为食品安全风险监测与评估。
E-mail: pengshaojie2008@qq.com