

机器学习在食品安全风险预警中的应用进展

张露菁¹, 周子文¹, 姚烨², 彭少杰¹

1. 上海市市场监督管理局信息应用研究中心, 上海 200030

2. 复旦大学公共卫生学院, 上海 200030

摘要：

食品安全风险预警是让监管跑在风险前面的重要技术手段。近年来, 机器学习作为一种新兴的技术, 凭借其强大的数据处理和分析能力, 展示了其在食品安全风险预警中的巨大潜力。本文介绍了食品安全风险预警的概念和当前国内外食品安全风险预警系统, 综述了各类机器学习方法的主要原理、基本特点和应用进展, 包括逻辑回归、最小绝对收缩和选择算子、支持向量机、随机森林、贝叶斯网络、极端梯度提升树、轻量级梯度提升机以及人工神经网络等, 提出了当前食品安全风险预警应用场景下机器学习的优缺点以及今后的发展方向, 特别是多模态数据融合和深度学习等先进技术将在未来食品安全风险预警中发挥更加重要的作用。

关键词：食品安全; 风险预警; 机器学习; 数据分析

Recent advances in application of machine learning for food safety risk early warning systems

ZHANG Lujing¹, ZHOU Ziwen¹, YAO Ye², PENG Shaojie¹ (1. Information Application Research Center, Shanghai Municipal Administration for Market Regulation, Shanghai 200030, China; 2. School of Public Health, Fudan University, Shanghai 200030, China)

Abstract:

Food safety risk early warning is a crucial technical approach to ensure that regulation stays ahead of potential risks. In recent years, machine learning, as an emerging technology, has demonstrated its immense potential in food safety risk early warning due to its powerful data processing and analysis capabilities. This paper introduced the concept of food safety risk early warning and the current food safety risk early warning systems both domestically and internationally. It reviewed the main principles, basic characteristics, and application progress of various machine learning methods, including logistic regression, least absolute shrinkage and selection operator, support vector machine, random forest, Bayesian network, extreme gradient boosting, light gradient boosting machine, and artificial neural networks. The paper also presented the advantages and disadvantages of machine learning in current food safety risk early warning application scenarios, as well as future development directions. In particular, advanced technologies such as multimodal data fusion and deep learning are expected to play an increasingly important role in future food safety risk early warning.

Keywords: food safety; risk early warning; machine learning; data analysis

1 风险预警与机器学习背景

食品安全预警特指针对食品安全状况所实施的“提前警示机制”, 旨在建立预警机制, 提前防范食品潜在的健康风险以及对国家、地区或企业决策可能造成的威胁^[1]。通过及时捕捉食品安全相关信息, 敏锐洞察潜在风险, 迅速启动预警机制, 以科学手段预防食品安全事故, 提升管理效能。

世界卫生组织创立了“全球疫情警报与反应网络”, 构建了“化学事件预警与反应体系”^[2]。美国建立了“食源性主动监测网络”系统来评估食源性疾病的危害程度^[3]。欧洲食品安全局构建了“食品与饲料快速预警系统”, 致力于食品安全信息的即时监测、评估与共享, 同时协调各成员国采取必要的应对措施^[4]。目前, 我国已通过整合监管实践中积累的监测、评估、消费、监督、投诉、舆情等多维数据, 构建起一个集分析预警与快速响应于一体的食品安全



DOI 10.11836/JEOM24562

基金项目

国家市场监督管理总局科技计划项目 (2022MK034)

作者简介

张露菁 (1991—), 女, 硕士, 工程师;
E-mail: 435953055@qq.com

通信作者

彭少杰, E-mail: pengshaojie2008@qq.com

作者中包含编委会成员 无

伦理审批 不需要

利益冲突 无申报

收稿日期 2024-11-17

录用日期 2025-06-18

文章编号 2095-9982(2025)10-0001-08

中图分类号 R15

文献标志码 A

► 本文链接、作者贡献申明

www.jeom.org/article/cn/10.11836/JEOM24562

► 引用

张露菁, 周子文, 姚烨, 等. 机器学习在食品安全风险预警中的应用进展 [J]. 环境与职业医学, 2025, 42(10): 1-8.

Funding

This study was funded.

Correspondence to

PENG Shaojie, E-mail: pengshaojie2008@qq.com

Editorial Board Members' authorship No

Ethics approval Not required

Competing interests None declared

Received 2024-11-17

Accepted 2025-06-18

► Link to this article, author contribution statement

www.jeom.org/article/en/10.11836/JEOM24562

► To cite

ZHANG Lujing, ZHOU Ziwen, YAO Ye, et al. Recent advances in application of machine learning for food safety risk early warning systems [J]. Journal of Environmental and Occupational Medicine, 2025, 42(10): 1-8.

风险监测与预警系统^[5]。海量的食品安全历史数据和即时数据在深度挖掘和精准分析方面始终存在难点,迫切需要新一代先进的数据处理和分析技术以实现预期的风险预警目标。

机器学习作为一种强大的数据分析工具,受到了许多研究者的青睐,为食品安全风险预警提供了新的思路和方法。机器学习经历漫长的演变过程而逐渐成熟,图1总结了自1960年以来推动人工智能领域变革的重要算法及其对人类历史进步的影响。1990年卷积神经网络的出现标志着深度学习的崛起,极大提升了计算机视觉性能,并推动了自动驾驶与医疗影像

解析等应用的发展。此外,1995年支持向量机(support vector machine, SVM)凭借其在高维空间中的强大分类能力,促进了复杂数据处理,特别是在文本分类和生物信息学中表现突出。随后,长短期记忆网络于1997年问世,该算法的出现克服了传统神经网络在处理序列数据时的局限,显著推动了自然语言处理和时间序列预测领域。最后,2014年生成对抗网络的引入开启了生成模型的新纪元,展现了巨大的潜力,进一步推动了艺术创作和虚拟现实等领域的进步。因此,这些算法的演变不仅提升了技术水平,而且在社会各层面产生了深远影响。




图1 机器学习模型时间发展顺序

Figure 1 Machine learning model temporal development

机器学习方法能够从大量数据中学习相应的模式和关系,实现预测和预警功能,克服了传统方法的局限性。食品安全风险预警领域常用的机器学习方法包括逻辑回归、最小绝对收缩和选择算子(least absolute shrinkage and selection operator, LASSO)、SVM、随机森林(random forest, RF)、贝叶斯网络、极端梯度提升树(extreme gradient boosting, XGBoost)和轻量级梯度提升机(light gradient boosting machine, LGBM)以及人工神经网络(artificial neural networks, ANN)。针对食品安全领域数据量庞大且数据结构复杂的问题,研究人员和从业者应综合考虑数据特性、任务需求和计算资源的限制,进行全面分析和决策,选择最合适的方法构建预警模型。特别是在大数据环境下,机器学习技术能够更有效地分析食品安全风险,为决策者提供风险决策的科学依据。本文将深入探讨多种机器学习方法在食品安全风险预警中的应用,分析其优缺点,并展望未来研究的主要方向。

2 食品安全风险预警机器学习方法与应用

食品领域数据量庞大,数据类型多样化,促使机

器学习算法展现出其独特的优势和适应能力。针对应用场景而言,逻辑回归分析可解释性强,简单、有效,适合用于二分类问题,如食品安全抽检结果(合格或者不合格)的判定;SVM在处理高维数据和小样本数据时表现优异,适合用于复杂的食品成分分类和品质评估。在面对高维、稀疏特征的数据时,LASSO方法适合用于从大量食品成分中筛选出对质量最有影响的变量。此外,RF通过集成多棵决策树,提供强大的抗过拟合能力,这对于复杂的食品安全数据至关重要^[6]。XGBoost在各类数据集上均表现良好,尤其适合食品成分分类和缺陷检测^[7]。LGBM专为大规模数据集设计,因其计算速度快的特性适合食品品质分析^[8]。面临图像和序列数据时,卷积神经网络在食品图像识别(如食品种类识别、缺陷检测等)方面展现出极高的效率和自动特征提取能力。ANN及其变种(长短期记忆网络)则更适合分析时间序列数据,如气候变化对农业生产的影响。在食品安全领域,模型的可解释性同样至关重要。可视化特性显著且逻辑简单的机器学习模型能够帮助从业者更好地理解模型预测结果,从而增进对食品安全决策的信任,如贝叶斯网络和决策树。

2.1 回归模型

逻辑回归是最广泛使用的统计模型,适用于二分类问题,可以扩展到多类别分类,如多项式逻辑回归。其基本思想是通过逻辑函数(即 Sigmoid 函数)将线性回归的输出值映射到一个介于 0 和 1 之间的概率值。一个经典应用是 Inoue 等^[9]研究分析了 529 起感染性食物中毒事件,运用多项逻辑回归模型开发了一款评估工具。该工具可根据患者的流行病学信息预测致病病原体,通过生成概率最高的病原体清单,确定事件最可能的致病原因。Ghorban 等^[10]利用逻辑回归模型分析消费者特征与食品消费决策的关系,从而揭示消费者行为的影响因素。在另一项研究中,Bian 等^[11]将逻辑回归模型应用在食品微生物污染影响的环境因素(如温度和湿度)上,结果表明这些因素是显著的风险因素,为食品贮存与管理提供了参考。该研究表明,逻辑回归可以用于评估和识别食品加工过程中可能的风险因素。另外,Nakamoto 等^[12]运用逻辑回归分析了磁性传感器对食品质地的评估数据,从而帮助评估未知的食品质地。

LASSO 回归是一种用于选择特征和正则化的线性回归技术,在线性回归损失函数中加入参数向量进行正则化(即所有回归系数绝对值之和),来防止模型过拟合。LASSO 的数学表达为最小化目标函数,其中损失函数与正则化项的结合促使部分参数趋于零,达到特征筛选的目的。LASSO 适用于高维数据,可有效减少模型的复杂性。该方法在基因组学、股票市场分析及社会经济数据分析中得到了广泛应用,其简洁性和特征选择能力使得 LASSO 成为高维数据建模的理想选择。He 等^[13]将 LASSO 用于预测食品中的营养成分,如热量、脂肪等。Lin 等^[14]通过 LASSO 研究消费者对不同食品特征的偏好。此外,Therdthai 等^[15]建立了 LASSO 模型,经特征选择后优化食品加工过程中影响食品质量的因素,该研究拓宽了 LASSO 在生物中的应用。

回归方法的优点在于模型简单、计算效率高,且结果易于解释。然而,当处理非线性关系时,其表现能力较差,容易受数据中的异常值影响。随着分析复杂性的提高,该方法不能有效地将结果用于对数据的回顾性分析。因此,需要结合其他机器学习方法来处理非线性和交互作用的问题,帮助食品安全决策者识别出数据中主要的影响因子,提供更为准确的结果。

2.2 支持向量机

SVM 是一种常用于分类问题的监督学习算法^[16],

通过构建一个超平面,以最大化类别间的间隔来进行分类。SVM 主要使用线性核函数、多项式核函数、Sigmoid 核函数等多种核函数^[17]将数据从原始空间映射到高维空间,以处理非线性问题。该算法可以在有限样本下进行统计学习,是模式识别领域中解决数据分类的一个重要工具^[18],其分类性能受数据特征的相关性影响^[19]。目前,SVM 在食品领域中可被用来判断果蔬及畜肉的成熟度^[20-21]、测定农产品中的水分、糖分等理化性质^[22-23]和蔬菜水果品质分级等,也可以应用于识别和分类潜在危险因素,评估食品安全风险,如鉴别肉制品掺假问题^[24]、食品中污染物的检测^[25]等。Mannaro 等^[26]利用 SVM 技术优化撒丁岛扁平面包生产,通过机器学习模型预测面包片大小,误差低至 2.2%,显著提升了产品质量监控效率。Crichton 等^[27]应用 SVM 算法,对 pH 值高于 5.9 和低于 5.6 的牛肉样本分类,准确率达 91%至 99%,提升屠宰后肉品质量控制。此举不仅降低了检测成本,还减少了样本损耗,揭示了 pH 值与肉质间的紧密联系。这些研究展示了 SVM 在食品检测中的强大能力,也奠定了机器学习在食品安全领域发展的基础。

食品安全数据常具有数量庞大、复杂度高等特点。SVM 的优点在于对高维数据的良好适应性及处理非线性数据的能力,但在处理大规模数据时,计算复杂度较高且参数调节复杂。

2.3 贝叶斯网络

贝叶斯网络通过图形方式表达随机变量及其条件的依赖关系,尤其适用于处理不确定性问题。通过整合先验信息,提出有效的估计模型参数分布的算法^[28]。在食品领域,贝叶斯网络可以应用在预测食品欺诈^[29-30]、风险评估、风险分析等方向。Yang 等^[31]将荟萃分析与贝叶斯网络结合,评估食品的整体质量和安全状况,并确定中国市场的风险食品。结果表明,中国市场上 98.26%的食品符合相关食品质量安全标准。Angelov 等^[32]使用贝叶斯网络(BBN)模型调查了全球粮食安全指数(GFSI)与可持续性和适应性相关指标之间的依赖关系。在实践中为政策制定者和从业者提供了制定有针对性的干预措施的见解。Ying 等^[33]构建了一个贝叶斯网络模型来评估食品中化学污染物的风险。在结合专家知识和实际数据的帮助下,为政府决策提供了科学依据。该项研究证明随机森林能量化风险,为政策制定者提供科学依据。Soon 等^[34]利用贝叶斯网络分析了假冒伪劣食品的风险,通过预测模型为消费者提供了更明确

的食品安全信息。贝叶斯网络的灵活性和对条件依赖关系的有效建模是其主要优点。然而,计算复杂性在大规模网络下会显著增加。

2.4 神经网络

神经网络是一种模仿动物神经网络行为特征进行分布式并行信息处理的算法数学模型,不会依赖物理假设和指令可视化^[35-36]。这种网络依靠系统的复杂程度,通过调整内部大量节点之间相互连接的关系,达到处理信息的目的^[26]。神经网络结构繁杂且庞大,其内部假设函数由数量庞大的非线性变换组成,这些非线性变换收敛得到极值点。在人工神经网络中,基本的计算单元被称为“神经元”或“节点”,这些节点通过类似于生物神经元的突触连接起来,每个神经元接收一组输入,对输入进行加权求和,然后通过一个非线性激活函数产生输出^[27]。

神经网络能够有效地处理大量复杂数据,包括食品生产、加工、储存和消费过程中的变量,被广泛应用于食品污染物的快速检测与识别^[37]。ANN 和卷积神经网络等模型被用于识别潜在的食品安全风险^[38],以响应和管理食品安全事件^[39]。有研究者利用循环神经网络等深度学习框架分析食品的存储条件、环境因素及历史销售数据,以预测食品的过期时间和潜在的质量下降^[40]。此外,神经网络模型在食品供应链监控中也得到了应用,通过实时分析供应链中的数据,识别潜在的安全隐患。例如,利用长短期记忆网络模型来预测供应链中的延误或中断^[41]。

在食品安全领域的研究中,多个神经网络模型显示出了卓越的应用效果,详见表 1。首先,在葡萄病害诊断中,反向传播神经网络(backpropagation Neural Network, BP)成功识别了 26 种常见病害,达到了 90.9%的精确度,展示了其在疾病诊断中的有效性,但在处理多样性和复杂病害方面仍有改进空间。针对蘑菇的干燥程度预测,ANN 模型通过优化后达到 0.994 的高相关性,表明其能够极为敏感地监控含水率,为蘑菇质量控制提供了有力支持。在农药与重金属检测方面,BP 模型在蔬菜中成功识别 11 种农药和 2 种重金属,展现了出色的精确度和灵敏度,但特异性为 83.9%,亟须提升以减少误报。另外,对于香蕉的成熟度评估,ANN 模型的准确率在 97.75%~100%,表明其在成熟度评估中的高效性,对市场销售策略具有积极影响。在肉制品合格率检测中,利用国家肉制品监督数据获得 93.75%的识别率,这说明神经网络模型对判断肉制品合格率方面

是准确可靠的,并有助于加强食品安全监管。复合调味料领域中,神经网络模型对于调味料感官方面的预测 MRE 值为 5.25%, R 值为 0.87,彰显其在识别高风险因素中的有效性,为食品行业的风险管理提供了新思路。最后,在乳制品质量风险因素分析中,以 97.54%的精确度识别出潜在风险因素,进一步凸显了该研究在保障乳制品安全方面的重要贡献。总体而言,这些研究充分展示了神经网络在食品安全检测与预警中的应用潜力,为各类食品的质量控制和安全管理奠定了坚实的基础。

这些研究充分展示了神经网络在食品安全预警系统中的广泛应用和有效性,尤其是在疾病诊断、污染检测和风险评估等领域。通过不同类型的神经网络模型,研究人员能够处理复杂的数据集,提供可靠的评估结果。这不仅能有效提高食品质量监控水平,还为科学管理食品安全提供了数据支持。然而,虽然目前的结果令人振奋,但可以看到实际应用中仍然存在挑战,包括模型的可解释性、数据采集的可靠性和适应性等。未来的研究可考虑如何提高模型的透明度、处理多源数据的能力以及优化资源配置以提高模型的实时性。

在食品污染检测和风险评估中,神经网络能够自动从原始数据中提取有用特征,减少了对传统特征工程的依赖^[42]。神经网络能够在实时监控中快速反应,对异常情况进行实时预警,提高了食品安全的应急响应能力^[43]。此外,神经网络最主要的优势是具有广泛的适用性,从食品库存管理到污染监测,神经网络适用于多个方面的食品安全管理,可以增强系统的整体效率^[44]。

然而,训练需要大量数据、计算复杂性高及模型的可解释性不足是神经网络的主要缺点。第一,神经网络的决策过程往往难以解释,具有黑箱特性。尤其在需要对食品安全领域可能导致监管和合规性问题的安全事件进行响应时,往往不能为食品安全监管者和决策者提供清晰的解释^[42]。第二,神经网络具有数据依赖性,网络训练通常需要大量高质量的标记数据。在数据稀缺或标记成本高的情况下,模型的性能可能受到制约^[45]。第三,在样本较少或特征冗余情况下,神经网络易出现过拟合,导致模型在新数据上的表现不佳^[44],可能会有过拟合的风险。在实际应用中,应结合其他方法以及技术进步,如传统算法和更先进的解释性方法,这些都可能有助于克服这些问题,从而提高食品安全预警系统的整体效果。

表 1 人工神经网络技术在食品安全预测中的应用
Table 1 Application of artificial neural network technology in food safety prediction

神经网络	食品品种	评价对象	评价目标	预警模型性能参数	参考文献
BP	葡萄	河北省怀来县2000—2003年间葡萄病害发生情况及相应的光照、湿度等气象数据	26种常见病害	精确度90.9%	[46]
ANN	蘑菇	头径在30~35 mm范围内的双孢蘑菇, 采摘后在-4 °C的条件下保存	预测含水率及干燥程度	相关系数R值为0.994、0.991、0.992	[47]
BP	蔬菜	江门市2016—2020年蔬菜食品安全抽检数据	11种农药, 2种重金属	精确度96.3%, 灵敏度96.8%, 特异性83.9%	[48]
ANN	香蕉	104根绿香蕉、57根黄香蕉、97根中熟香蕉、42根过熟香蕉	颜色、褐斑、成熟度	97.75%~100%	[49]
BP	肉制品	2015—2017年国家肉制品监督抽检3.1万批次检测数据	肉制品的合格率	识别率为93.75%	[50]
CNN	复合调味料	1963个市售复合调味料消费者感官评价	对复合调味料进行感官评价	MRE=5.25%, R=0.87	[51]
LSTM	乳制品	2015—2020年对外公开以及检测机构内部自行检测获得的543 336条乳制品检测信息	引发乳制品质量安全风险的因素	准确率为97.54%, 标准偏差为0.03	[52]

[注] LSTM为长短期记忆神经网络。

2.5 现代集成学习方法

决策树用样本属性的取值作为分支的树型结构, 适用于大规模样本分析^[53]。RF 是基于多棵决策树的集成学习方法, 预测性能和稳定性都得到了提升。该方法具有较强的抗过拟合能力, 处理高维数据时表现良好。Naseem 等^[54]利用决策树的方法对食品中的污染物进行分析, 达到了很好的效果, 可以用作建立基于风险的监测计划的工具。马红迪等^[55]以山东省 2016—2019 年食品添加剂抽检数据为样品, 从食品类别、添加剂种类与所属地区的不同角度描述了食品安全风险指数的统计特征, 并通过决策树和随机森林模型预测, 研究添加剂不合格项目对风险指数的影响, 最终以平均食品安全风险指数界, 将食品添加剂分为高风险和低风险两类。Reka 等^[56]应用随机森林模型对水果的新鲜程度、口感、质地和外观进行分类并预测其保质期, 获得了 95%的较高准确度, 通过开发准确的分类模型, 降低食品安全相关风险, 对食品行业产生重大影响。此研究表明, 随机森林在风险识别和预测任务中有着较强的适用性。De Santana 等^[57]采用随机森林结合拉曼光谱的方法对食品掺杂掺假进行了预测, 确保在各级生产中使用安全成分。

XGBoost 和 LGBM 是近期提出的集成学习模型, 前者利用梯度提升算法优化学习过程, 后者基于直方图的决策树算法加速模型构建, 两种算法都提高了模型性能和预测准确性。XGBoost 通过构建基于树的模型逐步改进预测, 每增加一棵树可减少当前模型的残差, 其目标函数结合了损失函数与正则化项, 以控制模型复杂度。XGBoost 性能优秀, 运算速度快, 能够有效处理大规模数据集。XGBoost 被用于分析食品中的物质对消费者接受度的影响。LGBM 通过将数据划分

为直方图提升训练速度, 同时优化内存使用效率。它采用新的生长策略以提高决策树的构建效率。该算法速度快, 适合处理大数据集, 内存占用少。在食品安全事件的分析中, XGBoost 和 LGBM 均表现出良好的性能^[58]。

以随机森林、XGBoost 和 LGBM 为代表的集成学习模型在许多机器学习任务中表现优异, 可以在一定程度上提高模型的准确性和泛化性能, 有效处理各种复杂问题。在一些特定应用场景下和实验条件下, 集成学习模型也存在许多不足。集成学习模型通常涉及多个模型的训练和预测, 需要更多的计算资源和时间, 当数据集较大或模型复杂时, 训练时间可能显著增加。其次, 该模型内部结构复杂, 超参数调整困难, 模型的整体可解释性差, 这可能使该模型在特定的任务中表现不佳或者在需要进行解释的应用场景中不够理想^[59]。

3 问题与展望

食品安全数据组成具有复杂性、多模态性, 往往是结构化和非结构化数据的混合使用。因此, 目前机器学习在食品领域的发展面临巨大挑战: 第一是食品安全数据来源, 包括传感器数据、实验室测试结果、用户反馈、社交媒体评论等。这些数据的格式(结构化和非结构化)和性质各异, 使得统一的数据处理和分析变得复杂^[60]。第二是数据清洗成本高。对于监督学习, 需大量的标注数据来训练模型, 而食品安全事件的发生相对稀少, 使得数据标注成为成本高昂且耗时的过程^[61]。第三是模型缺乏透明性和可解释性, 尤其是深度学习模型, 使模型在高度敏感的食品安全领域应用时面临信任危机^[62]。第四是食品安全涉及多学科的知

识,包括微生物学、化学、营养学等,不同学科的数据组成结构不同,机器学习模型常常难以有效整合这些跨学科的知识^[63]。

目前,我国食品安全数据仍存在共享机制不健全,数据流通慢,使用效率低等问题。因此,宏观上,应促进计算科学与食品科学、公共卫生等领域的合作,整合不同学科的知识,以提高模型的实用性和准确性。对于食品安全决策者而言,应加强监管部门的联动,保证检测数据的时效性和准确性,从而为后续食品安全风险预警新技术的研究应用做好基础性铺垫。

在食品行业,数据构成丰富多元,因此如何有效挖掘这些数据并结合机器学习模型为食品安全决策提供支持,成为当前的重要课题。特别是在食品安全领域,建立有效的预警模型,进而将其应用于各部门的日常监管工作,是关键的研究方向。未来的发展应集中在以下几个方面:第一,数据融合与技术创新。充分利用新技术手段,推动多模态数据融合,以便更全面地分析食品安全相关数据。深度学习等先进技术应被应用于处理和分析复杂的数据集,从而提高食品安全监测和预警的准确性。第二,模型可解释性的提升。针对机器学习模型,必须加强对其可解释性研究。发展新方法以提升模型的透明度,将有助于行业理解模型的预测结果,使得决策过程更加可信和可靠。第三,跨学科协作与集成应用。食品安全领域的机器学习应用面临着众多复杂挑战,未来的研究应加强跨学科协作,汇聚不同领域的专家和资源,共同推动更加高效的食品安全管理和监测系统的开发。通过以上三个方面的努力,将能够更好地应对食品安全风险,提升食品安全风险预警的精准性与实效性。

参考文献

- [1] GIUSTI A, GALGANI M, BARONTINI F, et al. Analysis of the original notifications in the Tuscany region "Rapid Alert System for Food and Feed" in the seven-year period 2015-2021[J]. *Ital J Food Saf*, 2024, 13(2): 12341.
- [2] PAPAPANAGIOTOU E P. Serious notifications on residues of veterinary medicinal products in food from RASFF (2012-2020)[J]. *Food Control*, 2023, 148: 109618.
- [3] FABO K R, NYE A M, GAGLEARDI J P, et al. Evaluation of changes in citalopram prescribing patterns following a US Food and Drug Administration Alert: A retrospective cohort study[J]. *Prim Care Companion CNS Disord*, 2015, 17(1): 10.4088/PCC.14m01657.
- [4] PAPAPANAGIOTOU E P. Serious notifications on food contact materials in the EU RASFF[J]. *Vet Sci*, 2021, 8(4): 56.
- [5] 耿雪峰, 张晶, 庄众, 等. 2002—2016 年中国椰毒假单胞菌食物中毒报告事件的流行病学分析[J]. *卫生研究*, 2020, 49(4): 648-650.
- GENG X F, ZHANG J, ZHUANG Z, et al. Epidemiological analysis of reported food poisoning events caused by *Pseudomonas cocovenenans* in China, 2002-2016[J]. *J Hyg Res*, 2020, 49(4): 648-650.
- [6] KORB K B, NICHOLSON A E. Bayesian artificial intelligence[M]. 2nd ed. Boca Raton: CRC Press, 2010.
- [7] CHEN T, GUESTRIN C. XGBoost: a scalable tree boosting system[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. San Francisco: ACM, 2016: 785-794.
- [8] KE G, MENG Q, FINLEY T, et al. LightGBM: a highly efficient gradient boosting decision tree[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems. Long Beach: Curran Associates Inc., 2017: 3149-3157.
- [9] INOUE H, SUZUKI T, HYODO M, et al. Evaluation of multinomial logistic regression models for predicting causative pathogens of food poisoning cases[J]. *J Vet Med Sci*, 2018, 80(8): 1223-1227.
- [10] GHORBAN TANHAEI, BOOZARY, et al. Predictive analytics in customer behavior: anticipating trends and preferences[J]. *Results in Control and Optimization*, 2024, 17: 100462.
- [11] BIAN W, HOU H, et al. Evaluating the spatial risk of bacterial foodborne diseases using vulnerability assessment and geographically weighted logistic regression[J]. *Remote Sens*, 2022, 14: 3613.
- [12] NAKAMOTO, H, NISHIKUBO, D, et al. Food Texture Evaluation Using Logistic Regression Model and Magnetic Food Texture Sensor. *Journal of Food Engineering* 2018, 222, 20-28.
- [13] HE H J, ZHANG C, et al. Improved prediction of vitamin C and reducing sugar content in sweetpotatoes using hyperspectral imaging and LARS-enhanced LASSO variable selection[J]. *J Food Composition Analysis*, 2024, 132: 106350.
- [14] LIN L, GU Y C. Aesthetic appetites: exploring consumer preferences through conjoint analysis[J]. *Food Quality and Preference*, 2025, 122: 105281.
- [15] THERDTHAI N. Chapter 15-modeling and optimization of food processes in engineering principles of unit operations in food processing[J]. Woodhead Publishing, 2021, pp 419-441.
- [16] 袁彦芬, 王兴芬. 基于 SVM 的生鲜食品货架期预测[J]. *物流技术*, 2015, 34(19): 64-67.
- YUAN Y Y, WANG X F. Study on fresh food shelf life forecasting based on SVM[J]. *Logist Technol*, 2015, 34(19): 64-67.
- [17] 游清顺, 王建新, 张秀宇, 等. 基于支持向量机的食品安全抽检数据分析方法[J]. *软件工程*, 2019, 22(2): 29-31.
- YOU Q S, WANG J X, ZHANG X Y, et al. SVM-based analysis on food safety sampling and inspection data[J]. *Software Eng*, 2019, 22(2): 29-31.
- [18] KOK Z H, MOHAMED SHARIFF A R, ALFATNI M S M, et al. Support vector machine in precision agriculture: a review[J]. *Comput Electron Agric*, 2021, 191: 106546.
- [19] WESTON J, MUKHERJEE S, CHAPELLE O, et al. Feature selection for SVMs[C]//Proceedings of the 14th International Conference on Neural Information Processing Systems. Denver: MIT Press, 2000: 647-653.
- [20] 莫松涛, 董涛, 赵汐璇, 等. 基于遗传算法与 SVM 的香蕉果实成熟度判别模型[J]. *果树学报*, 2022, 39(12): 2418-2427.
- MO S T, DONG T, ZHAO X X, et al. Discriminant model of banana fruit maturity based on genetic algorithm and SVM[J]. *J Fruit Sci*, 2022, 39(12): 2418-2427.
- [21] 王文秀, 彭彦昆, 孙宏伟, 等. 二维相关可见-近红外光谱结合支持向量机评价猪肉新鲜度[J]. *食品科学*, 2018, 39(18): 273-279.
- WANG W X, PENG Y K, SUN H W, et al. Evaluation of pork freshness using two-dimensional correlation visible/near-infrared spectroscopy combined

- with support vector machine[J]. Food Sci, 2018, 39(18): 273-279.
- [22] 张立欣, 杨翠芳, 张晓, 等. 基于近红外光谱和支持向量机回归参数调优的羊肉含水量检测[J]. 食品与发酵工业, 2022, 48(12): 255-260.
ZHANG L X, YANG C F, ZHANG X, et al. Detection and parameter optimization of moisture content in mutton based on near infrared spectroscopy and SVR[J]. Food Ferment Ind, 2022, 48(12): 255-260.
- [23] 黄康, 汪辉君, 徐惠荣, 等. 基于最小二乘支持向量机的番茄汁糖酸度分析研究[J]. 光谱学与光谱分析, 2009, 29(4): 931-934.
HUANG K, WANG H J, XU H R, et al. NIR spectroscopy based on least square support vector machines for quality prediction of tomato juice[J]. Spectrosc Spectral Anal, 2009, 29(4): 931-934.
- [24] 张丽华, 相启森, 李顺峰, 等. 基于支持向量机的近红外光谱技术鉴别掺假牛肉[J]. 西北农林科技大学学报(自然科学版), 2016, 44(12): 201-205.
ZHANG L H, XIANG Q S, LI S F, et al. Identification of adulteration of minced beef with near infrared spectroscopy based on support vector machine[J]. J Northwest A&F Univ (Nat Sci Ed), 2016, 44(12): 201-205.
- [25] ZHU L, SPACHOS P. Support vector machine and YOLO for a mobile food grading system[J]. Internet of Things, 2021, 13: 100359.
- [26] MANNARO K, BAIRE M, FANTI A, et al. A robust SVM color-based food segmentation algorithm for the production process of a traditional Carasau bread[J]. IEEE Access, 2022, 10: 15359-15377.
- [27] CRICHTON S O J, KIRCHNER S M, PORLEY V, et al. High pH thresholding of beef with VNIR hyperspectral imaging[J]. Meat Sci, 2017, 134: 14-17.
- [28] ELEGBEDE C F, PAPADOPOULOS A, GAUVREAU J, et al. A Bayesian network to optimise sample size for food allergen monitoring[J]. Food Control, 2015, 47: 212-220.
- [29] WANG X, ZHOU M, JIA J, et al. A Bayesian approach to real-time monitoring and forecasting of Chinese foodborne diseases[J]. Int J Environ Res Public Health, 2018, 15(8): 1740.
- [30] BOUZEMBRAK Y, MARVIN H J P. Prediction of food fraud type using data from Rapid Alert System for Food and Feed (RASFF) and Bayesian network modelling[J]. Food Control, 2016, 61: 180-187.
- [31] YANG Y, WEI L, et al. Application of Bayesian modelling to assess food quality & safety status and identify risky food in China market[J]. Food Control, 2019, 100: 111-116.
- [32] QAZI A, AL-MHDAWI M K S. Sustainability and adaptation dynamics in global food security: A Bayesian belief network approach[J]. J Cleaner Production, 2024, 467: 142931.
- [33] YING X, LU A, CAI Q, et al. Bayesian network modeling applied to food risks: Data from general administration of customs of China as an example[J]. Applied Food Research, 2024, 4(2): 100565.
- [34] SOON J M. Application of Bayesian network modelling to predict food fraud products from China[J]. Food Control 2020, 114, 107232.
- [35] WU Y, ZHANG G, ZHANG Y, et al. Design of biogas production prediction model based on improved BP neural network and genetic algorithm[J]. J Phys: Conf Ser, 2022, 2401: 012076.
- [36] ZHANG H, NIU F, ZHANG J, et al. Prediction of three-dimensional fractal dimension of hematite flocs based on particle swarm optimization optimized back propagation neural network[J]. Min Metall Explor, 2022, 39(6): 2503-2515.
- [37] ZHAO J, YU Y, et al. Convolutional neural networks in the realm of food quality and safety evaluation: current achievements and future prospects[J]. Trends in Food Science & Technology, 2025, 163: 105162.
- [38] ZHAO Z, DONG J, et al. A survey on machine learning methods for food safety risk assessment: approaches, challenges, and future outlook[J]. Engineering Applications of Artificial Intelligence, 2025, 154: 110960.
- [39] DING H, WANG L, et al. Application of deep learning in food safety detection and risk early warning[J]. Food Science, 2025, 46(6): 295-308.
- [40] SHI C, ZHAO Z, et al. Artificial neural network-based shelf life prediction approach in the food storage process: A review[J]. Crit Rev Food Sci Nutr, 2024, 64(32): 12009-12024.
- [41] PACELLA M, PAPADIA G, et al. Evaluation of deep learning with long short-term memory networks for time series forecasting in supply chain management[J]. Procedia CIRP, 2021, 99: 604-609.
- [42] 包峰, 王娟, 任振辉. 基于 BP 网络的葡萄病害发生预测系统的开发研究[J]. 安徽农业科学, 2010, 38(14): 7660-7662.
BAO F, WANG J, REN Z H. Research of system based on BP network for prediction of grape disease[J]. J Anhui Agric Sci, 2010, 38(14): 7660-7662.
- [43] TARAFDAR A, SHAHI N C, SINGH A. Freeze-drying behaviour prediction of button mushrooms using artificial neural network and comparison with semi-empirical models[J]. Neural Comput Appl, 2019, 31(11): 7257-7268.
- [44] 赵杰斌, 黄穗东, 孙远明, 等. 基于数据挖掘的江门市蔬菜食品安全风险分析与预测[J]. 食品工业科技, 2023, 44(20): 281-288.
ZHAO J B, HUANG S D, SUN Y M, et al. Safety risk analysis and prediction of vegetable in Jiangmen City based on data mining[J]. Sci Technol Food Ind, 2023, 44(20): 281-288.
- [45] MAZEN F M A, NASHAT A A. Ripeness classification of bananas using an artificial neural network[J]. Arab J Sci Eng, 2019, 44(8): 6901-6910.
- [46] 王若衡, 江生, 王钰麒, 等. 肉制品 BP 神经网络风险预警模型构建研究[J]. 中国食品工业, 2022(6): 114-118, 128.
WANG R H, JIANG S, WANG Y Q, et al. Construction of BP neural network risk early warning model for meat products[J]. China Food Ind, 2022(6): 114-118, 128.
- [47] GENG Z, WANG X, JIANG Y, et al. Novel IAPSO-LSTM neural network for risk analysis and early warning of food safety[J]. Expert Syst Appl, 2023, 230: 120747.
- [48] 白宝光, 朱洪磊, 范清秀. BP 神经网络在乳制品质量安全风险预警中的应用[J]. 中国乳品工业, 2020, 48(7): 42-45, 57.
BAI B G, ZHU H L, FAN Q X. Application research of BP neural network in dairy product quality and safety risk[J]. China Dairy Ind, 2020, 48(7): 42-45, 57.
- [49] VAN ASSELT E D, NOORDAM M Y, PIKKEMAAT M G, et al. Risk-based monitoring of chemical substances in food: prioritization by decision trees[J]. Food Control, 2018, 93: 112-120.
- [50] 李笑曼, 臧明伍, 赵洪静, 等. 基于监督抽检数据的肉类食品安全风险分析及预测[J]. 肉类研究, 2019, 33(1): 42-49.
LI X M, ZANG M W, ZHAO H J, et al. Analysis and prediction of meat product safety based on supervision and sampling data[J]. Meat Research, 2019, 33(1): 42-49.
- [51] 束沁烜, 张佳汇, 王琪, 等. 基于消费者感官评价能力评估的近红外固态复合调味料鲜美感 AI 模型构建[J]. 光谱学与光谱分析, 2025, 45(8): 2228-2233.
SHU Q D, ZHANG J H, WANG Q, et al. Construction of a NIR solid-state composite seasoning freshness AI model based on consumer sensory evaluation ability assessment[J]. Spectroscopy and Spectral Analysis, 2025, 45(8): 2228-2233.
- [52] 陈晨, 尹佳, 董曼, 等. 基于灰色数据预处理的 WD-LSTM 模型对乳制品质量安全风险的预测预警分析[J]. 现代食品科技, 2023, 39(1): 300-310.
CHEN C, YIN J, DONG M, et al. Predictive early warning analysis of dairy

- product quality and safety risks based on grey data pre-processing using the WD-LSTM model[J]. *Modern Food Science and Technology*, 2023, 39(1): 300-310.
- [53] 唐冠宁, 姚京裕, 刘阳. 基于随机森林模型的食品质量检测大数据分析系统研究 [J]. *质量与认证*, 2025(4): 113-116.
- TANG G N, YAO J Y, LIU Y. Research on a big data analysis system for food quality inspection based on random forest models[J]. *Quality and Certification*, 2025(4): 113-116.
- [54] NASEEM S, RIZWAN M. The role of artificial intelligence in advancing food safety: A strategic path to zero contamination[J]. *Food Control*, 2025, 175: 111292.
- [55] 马红迪. 基于决策树和随机森林模型的食品安全风险预警 [D]. 东北财经大学, 2020.
- MA H D. Food safety risk early warning based on decision tree and random forest models[D]. Dongbei University of Finance and Economics[D], 2020.
- [56] REKA S, BAGELIKAR A. Deep learning-based classification of rotten fruits and identification of shelf life[J]. *Computers, Materials and Continua*, 2024, 78(1): 781-794.
- [57] DE SANTANAN F B, BORGES NETO W, et al. Random forest as one-class classifier and infrared spectroscopy for food adulteration detection[J]. *Food Chemistry*, 2019, 293: 323-332.
- [58] LI Q, CHEN H, et al. The impact of climate change on China's food security considering artificial intelligence level: Based on XGBoost and RIME-CNN-LSTM-ATT models[J]. *Resources, Conservation and Recycling*, 2026, 224: 108539.
- [59] 左恩光. 基于深度学习的食品安全风险发现和预警模型研究 [D]. 新疆大学, 2023.
- ZUO ENGUANG. The research on food safety risk discovery and early warning model based on deep learning[D]. Xinjiang University, 2023
- [60] SAHA D, MANICKAVASAGAN A, et al. Machine learning techniques for analysis of hyperspectral images to determine quality of food products: A review[J]. *Current Research in Food Science*, 2021, 4: 28-44.
- [61] 刘光惠, 陈卓越, 鲜思东, 等. 基于随机森林的食品安全监测预警研究 [J]. *重庆工商大学学报 (自然科学版)*, 2025, 42(5): 27-35.
- LIU G H, CHEN Z C, XIAN S D, et al. Research on food safety monitoring and early warning based on random forest[J]. *J Chongqing Technology and Business University(Natural Sciences Edition)*, 2025, 42(5): 27-35.
- [62] OKOYE C O, ABHADIOMHEN S E, et al. Machine learning-based predictive modeling of foodborne pathogens and antimicrobial resistance in food microbiomes using omics techniques: A systematic review[J]. *Food Research International*, 2025, 221: 117255.
- [63] 高亚男, 王文倩, 王建新. 集成模糊层级划分的 LightGBM 食品安全风险预警模型: 以肉制品为例 [J]. *食品科学*, 2021, 42(1): 197-207,210.
- GAO Y N, WANG W Q, WANG J X. A food safety risk prewarning model using lightGBM integrated with fuzzy hierarchy partition: A case study for meat products[J]. *Food Science*, 2021, 42(1): 197-207,210.

(英文编辑: 汪源; 责任编辑: 陈姣)